

INFORME FINAL

1. Contexto y Objetivo

El mercado de plataformas de streaming exige una comprensión precisa del comportamiento de sus usuarios para optimizar las estrategias de retención y recomendación. Este proyecto surge de la necesidad de analizar la relación existente entre las características demográficas de los consumidores y sus niveles de engagement.

El **objetivo principal** es estructurar un pipeline de datos reproducible que permita auditar la calidad de la información, descubrir patrones de visualización y reducir la dimensionalidad del dataset mediante Análisis de Componentes Principales (PCA), transformando variables correlacionadas en componentes limpios y ortogonales utilizables para futuras segmentaciones avanzadas.

2. Dataset y Calidad Inicial

El estudio se basó en el dataset original alojado en `data/raw/`. La fase de inspección inicial (`01_inspeccion_inicial.ipynb`) permitió auditar las dimensiones del set de datos y la naturaleza de sus variables, identificando las siguientes métricas críticas de calidad:

- **Variables clave bajo análisis:** `age` (numérica entera) y `monthly_watch_time_mins` (numérica flotante).
- **Valores faltantes / Nulos:** Se detectaron anomalías y registros nulos distribuidos aleatoriamente en la columna de tiempo de consumo.
- **Duplicados:** Se identificaron registros idénticos que sesgaban las métricas descriptivas iniciales.

3. Decisiones de Limpieza y Preparación

Evitando la imputación a ciegas o automatizada, cada acción aplicada en el módulo `02_calidad_y_limpieza.ipynb` se respaldó con evidencia técnica y quedó registrada de forma transparente en el log de transformaciones.

Nota: El registro histórico exacto de cambios se encuentra disponible para auditoría en `logs/pipeline_log.csv`.

4. Hallazgos del Análisis Exploratorio (EDA)

A través de las 5 visualizaciones requeridas integradas en la aplicación de Streamlit, se extrajeron conclusiones analíticas que trascienden la mera descripción visual:

- **Análisis Univariado:** La distribución de la edad muestra una dispersión heterogénea, mientras que los minutos de reproducción mensuales presentan una concentración marcada en ciertos segmentos de consumo.
- **Comportamiento Bivariado y Multivariado:** Se constató una correlación lineal entre la edad de los usuarios y su tiempo de permanencia en la plataforma. Esta redundancia estadística confirmó la necesidad de aplicar una técnica de extracción de características para evitar la multicolinealidad.

5. Análisis de Componentes Principales (PCA)

Para preparar los datos, se aplicó un escalamiento estándar (*StandardScaler*) sobre las variables `age` y `monthly_watch_time_mins`, asegurando que la diferencia de escalas no distorsionara el algoritmo. Los resultados del modelo arrojaron:

- Varianza Explicada: El Componente 1 (PC1) captura el 50.20% de la variabilidad, mientras que el Componente 2 (PC2) absorbe el 49.80% restante. En conjunto, explican el 100.00% de la varianza original, logrando una transformación sin pérdida de información.
- Interpretación de Componentes (Loadings):
 - PC1 (Índice de Madurez y Consumo General): Carga positiva simétrica (0.707) en ambas variables. Define de forma unificada a perfiles de usuarios adultos con alta retención en la plataforma.
 - PC2 (Factor de Engagement Joven): Contraste perfecto con carga negativa en edad (-0.707) y positiva en minutos (0.707). Aísla eficientemente el fenómeno de usuarios jóvenes con consumos de tiempo sumamente agresivos.

6. Conclusiones, Limitaciones y Próximos Pasos

Conclusiones: El pipeline desarrollado procesó con éxito los datos crudos y los transformó en un espacio bidimensional completamente ortogonal. Los nuevos componentes (PC1 y PC2) eliminan la redundancia detectada en el EDA, quedando optimizados como variables de entrada limpias para posteriores algoritmos de aprendizaje no supervisado (K-Means).

Limitaciones: El alcance de las conclusiones se encuentra condicionado estrictamente por la información disponible y el uso exclusivo de dos variables para el modelado de reducción, lo que restringe la segmentación a un plano bidimensional básico.